

Plataforma tecnológica para el Fortalecimiento de las capacidades nacionales
para el aprovechamiento de Fuentes No Convencionales de Energía

Analítica de Datos en Python

IA aplicada a Fuentes No Convencionales de Energía

PhD. Ana Isabel Oviedo | ana.oviedo@upb.edu.co
PhD. Ferney Amaya | Ferney.amaya@upb.edu.co





Objetivo del curso

Desarrollar competencias en el análisis de datos con técnicas de Inteligencia Artificial, aplicadas a proyectos de FNCE, mediante el uso Python.



Desarrollo temático

Módulo	Temas principales
Introducción al análisis de datos con IA	Ramas de la IA. Áreas del aprendizaje de máquina. Diseño de soluciones con IA.
Introducción a Python y al análisis exploratorio de datos	Entorno de trabajo de Google Colab, principios de programación, manipulación de datos con Pandas
Preparación de datos	Limpieza de nulos y atípicos. Transformaciones: normalización y variables dummy.
Minería descriptiva	Clustering con K-means.
Minería predictiva	División 70-30 y validación cruzada. Medidas de evaluación para clasificación y regresión. Árboles de decision, Random Forest y KNN.



Agenda

1. Introducción al Análisis de datos con IA
2. Introducción a Python
3. Preparación de Datos
4. Minería Descriptiva
5. Minería Predictiva



Introducción al **Análisis de datos con IA**




IA

Rama de la informática que desarrolla procesos que imitan la inteligencia de los humanos y otros seres vivos.

Aprendizaje de Máquinas



Predicción de ventas



Detección temprana de enfermedades

Visión Artificial




Agricultura inteligente




Inspección en manufactura

Procesamiento de Lenguaje Natural



Asistentes personales




Chatbots

Robótica



Robot de atención al cliente



Humanoide (Hanson Robotics)

Agentes Inteligentes



Sistemas autónomos



Automatización de tareas

IA Generativa



Generación de texto



Generación de audio

Aprendizaje de máquinas



Tipos de Datos



Estructurados

- Variables Numéricas (cuantitativas)

- Peso
- Salario
- Edad
- Ventas

- Variables Categóricas (cualitativas)

- Sexo = {Hombre, Mujer}
- Estado civil= {Casado, Soltero}
- Estrato= {1,2,3,4,5}

Fechas (date)

No Estructurados

- Texto
- Imágenes
- Audio
- Video



Minería de Datos

Extracción de conocimiento a partir de fuentes masivas de datos.

- Técnicas Estadísticas
- Técnicas de Aprendizaje de Máquinas (IA)



Transformar datos en conocimiento!

Tipos de Análisis en Minería de Datos

Minería Predictiva



- Predecir riesgos
- Predecir activación de nuevos clientes
- Series de tiempo
- Predecir inventario

Minería Descriptiva



- Perfil de los clientes
- Selección de factores
- Detección de anomalías
- Canasta de mercado

Tipos de Análisis en Minería de Datos

Requerimiento en los Datos:

- Histórico de datos
- Datos etiquetados: existencia de una variable objetivo y varias variables predictoras
- Debe existir relación entre las variables predictoras y la objetivo.

Minería Predictiva

Predicción Discreta o Clasificación
Predicción Continua o Regresión






Minería Predictiva

Predicción Discreta o Clasificación

Predicción de una variable objetivo categórica.

* Ejemplo: Predecir los estudiantes que ganarán un curso






Minería Predictiva

Predicción Continua o Regresión

Predicción de una variable objetivo numérica.

* Ejemplo: Estimar la expectativa de vida de un cliente.




Tipos de Análisis en Minería de Datos

Requerimiento en los Datos:

- Datos activos o actuales
- Datos No etiquetados

Minería Descriptiva


Agrupamiento / Clustering



Minería Descriptiva


Agrupamiento / Clustering

Descubrimiento de
similitudes en los
datos.




* Ejemplos: Diseñar
estrategias de mercadeo
según el tipo de cliente.
Detección de anomalías
identificando datos que se
alejen de los centroides de
agrupación

Id	Atributo 1	Atributo 2	...	Atributo n
1	10	alto		35
2	35	bajo		54
3	43	medio		28
4	26	bajo		65
5	87	alto		32
6	45	alto		29
7	76	bajo		55
8	5	medio		46
9	12	medio		43
10	54	bajo		27



*Descripción
en grupos*





Introducción a **Python**

Programación

- Código de máquina: 1s y 0s
- Lenguaje ensamblador

```
-u 100 la
```

```
OCFD:0100 BA0B01
OCFD:0103 B409
OCFD:0105 CD21
OCFD:0107 B400
OCFD:0109 CD21
```

```
MOV     DX,010B
MOV     AH,09
INT     21
MOV     AH,00
INT     21
```

Lenguaje de máquina
del **Intel 8088** (1979).

- Lenguaje de alto nivel

~1842, **Ada Lovrance**

1955 - Fortran

1959 - COBOL

1969 - B (precursor C)

1969 y 1973 - **C**

1980 - **C++** (C con clases)

1983 - Ada

1991 - **Python**

1991 - Visual Basic

1991 - *HTML (Informático)*

1995 - Java

1995 - Delphi (Object Pascal)

1995 - JavaScript

1995 - PHP

2001 - **C#** (Sharp)

2001 - Visual Basic .NET

2005 - Scratch

2009 - Go

2011 - Dart

2014 - Swift



Enlace de apoyo

<https://github.com/FerneyOAmaya/Competencias-Digitales>



Proceso de un programa

1. Codificación: se escribe el código fuente del programa: Python, C++ o JavaScript

2. Traducción a Lenguaje de máquina:

- Compilador: Convierte todo el código fuente generando un archivo ejecutable. Lenguaje compilado: C y C++.
- Intérprete: Ejecuta el código línea por línea en tiempo real. Lenguaje interpretado: Python.

3. Ejecución: el sistema operativo (Windows, macOS, Linux y Android) gestiona la ejecución del programa, asignando recursos como memoria y tiempo del procesador.



Python y Colab



- Gratuito y de código abierto.
- Amplia comunidad de desarrolladores y recursos disponibles.
- Empleado en aprendizaje de máquina (machine learning) y ciencia de datos.



¿Qué es Google Colaboratory?

- Colaboratory, o "Colab" para abreviar, es un producto de Google Research.
- Permite escribir y ejecutar código de Python en el navegador.
- Útil para tareas de aprendizaje automático, análisis de datos y educación.







Google Colab

1 Ingresar a la cuenta de Google.


3 Instalarlo en la cuenta de Google:



2 En Drive:



Tipos de datos



Case sensitive

Pasa saber el tipo de dato:

```
type ( )
```

- Snake Case: guiones bajos para separar palabras: `nombre_usuario`.
- Camel Case: La primera letra de cada palabra (excepto la primera) en mayúscula: `nombreUsuario`.
- Mayúsculas
Constantes: para valores constantes:

```
PI = 3.1416
```



Restricciones al nombrar variables

- Solo pueden contener letras (a-z, A-Z), números (0-9) y guiones bajos (_).
- Deben comenzar con letra (a-z, A-Z) o guion bajo (_).
- No pueden ser palabras reservadas de Python (como if, else, for, while, def).



Operadores básicos

Numéricos

Operación	En Python
Adición	+
Sustracción	-
Multiplicación	*
División	/
Exponenciación (3^2 en Python sería <code>3**2</code>)	**
Módulo de la división	%
Resultado de la división redondeando al menor entero	//

Cadenas de caracteres

Operación	En Python
Concatenación de cadenas de caracteres	+
Repetición de cadenas de caracteres	*



Entradas, salidas, casting

Entradas de datos:

```
input()
```

Salidas de datos:

```
print()
```

Observar el tipo de dato:

```
type()
```

*Conversión
de tipos de
datos
(casting):*

a entero:

```
int()
```

a flotante:

```
float()
```

a string:

```
str()
```



Estructuras de programación

Condicional

```
if <condición>:  
    ...  
elif:  
    ...  
else:  
    ...  
#END IF
```

Mientras

```
while <condición>:  
    ...  
#END WHILE
```

For

```
for <variable compuesta>:  
    ...  
#END FOR
```



Operadores de comparación

Comparación	Símbolo
Igual	==
No igual (diferente)	!=
Mayor que	>
Menor que	<
Mayor o igual que	>=
Menor o igual que	<=
Igual	==



Ejemplos de estructuras

```
numero = int(input("Ingresa un número: "))

if numero > 0:
    print("El número es positivo")
elif numero == 0:
    print("El número es cero")
else:
    print("El número es negativo")
```

```
contador = 3

while contador > 0:
    print(contador)
    contador = contador - 1
#END WHILE

print("Despegue")
```

```
cadena = "Hola"

for c in cadena:
    print(c)
```



Funciones y métodos

Función: bloque de código reutilizable.

- Nativa (built-in): `print()`, `len()`, `max()` ...
- Definida por el usuario.

Método: asociada a un objeto y tipo de dato:

`objeto.metodo()`

Funciones

- Facilita la lectura, depuración, distribución de actividades y actualización.
- Pueden reusarse en otros programas.
- Buena práctica: debe ser realizar una única acción, reutilizable y por lo tanto, tan genérica como sea posible.

```
def resta(a, b):  
    c = a - b  
    return c
```

```
valor = resta(6, 2)  
print(valor)
```



Ejemplos de funciones

```
def imprime():  
    print("Hola mundo!")  
  
imprime()
```

```
def resta(a, b):  
    c = a - b  
    return c  
  
valor = resta(6, 2)  
print(valor)
```

```
def operaciones(a, b):  
    suma = a + b  
    resta = a - b  
    mul = a * b  
    return suma, resta, mul  
  
s, r, m = operaciones(10, 5)  
print("Suma:", s, "Resta:", r, "Mul:", m)
```



Listas y diccionarios

```
lista = [5, 'hola', [2, 8, 4], ['si', 'no'], "Python"]
```

```
traductor = {  
    "apple": "manzana",  
    "banana": "plátano",  
    "orange": "naranja",  
    "strawberry": "fresa",  
    "grape": "uva"  
}
```



Pandas

Un DataFrame es una tabla bidimensional para manejar datos (filas y columnas).

Ejemplo:

Índice	Nombre	Edad	Ciudad
0	Ana	22	Bogotá
1	Luis	28	Medellín
2	Marta	24	Cali

Valores

- Fila, Columna
- Nombre de la columna
- Índices
- Valores



Pandas - Crear

Creación:

Índice	A	B
10	1	2
20	3	4
30	5	6

```
import numpy as np
import pandas as pd

datos = np.array([[1, 2], [3, 4], [5, 6]])
df = pd.DataFrame(datos, index=[10, 20, 30], columns=['A', 'B'])

df = pd.DataFrame(
    {'A': [1, 2, 3], 'B': [4, 5, 6]}, index=[10, 20, 30])
```

Exploración:

- df.columns
- df.index
- df.values
- df.dtypes
- df.loc[índice , nombre_columna]
- df.iloc[posicion_fila, posicion_columna]



Pandas – Crear y cargar

Importar desde un archivo

Formatos
almacenamiento

Id	Nombre	Edad	Hijos
0	Jorge	28	2
1	Carlos	36	
2	Lina		1
3	Sofía	40	0

JSON: (JavaScript Object Notation)

```
{  
  "Nombre":  
    :{"0":"Jorge", "1":"Carlos", "2":"Lina", "3":"Sofía"},  
  "Edad":  
    :{"0":28,"1":36,"2":null,"3":40},  
  "Hijos":  
    :{"0":2,"1":null,"2":1,"3":0} }  
}
```

CSV: (comma-separated values)

```
Id,Nombre,Edad,Hijos  
0,Jorge,28,2  
1,Carlos,36,  
2,Lina,,1  
3,Sofía,40,0
```



Pandas – Consultar

Acciones:

- Valores únicos: `.unique()`
- Acceder: `.loc[]`, `.iloc[]`
- Calcular: `.max()`, `.min()`
- No nulos: `.notnull()`
- Filtrar: `.between()`
- Ordenar: `sort_values()`

Desde: Github Ferney Amaya → Competencias-Digitales → Libro “Librería Pandas” → Cargar el Dataframe de la sección 5

<https://github.com/FerneyOAmaya/Competencias-Digitales>



Pandas - groupby

```
df.groupby([col1, col2 ...])[col_val1, col_val2 ...].función_agregación()
```

- col1, col2 ... : columnas a agrupar
- col_val: columnas a aplicar la función de agregación
- función_agregación: Ejemplos: `sum()`, `mean()`, `count()`

Desde: Github Ferney Amaya → Competencias-Digitales → Libro “Librería Pandas” → Cargar el Dataframe de la sección 5

<https://github.com/FerneyOAmaya/Competencias-Digitales>





Preparación de Datos



Preparación de los Datos

1. Integración de los datos
2. Eliminar variables irrelevantes y redundantes
3. Descripción estadística de los datos
4. Limpieza de datos atípicos-errores
5. Limpieza de datos nulos
6. Transformaciones según el método de ML
 - Normalización
 - Creación de dummies



1. Integración de Datos

Se debe crear un registro por persona/producto/servicio/sede con todas las variables integradas:

ELIMINAR
registros con lds
duplicados

Id	Nombre	Estrato	Sexo	Enfermedad
1	Ana Perez	3	F	SI
2	Mauricio Rios	2	M	NO
3	Samuel Ochoa	4	M	NO
4	Emilia Oviedo	3	F	NO
5	Carmen Reyes	4	F	SI
6	Alberto Arenas	4	M	NO
7	Maria Betancur	3	M	NO
8	Manuel Regino	2	M	NO
9	Sara Merino	2	F	NO
10	Pepe Corrales	2	M	SI
11	Raul Poveda	4	M	NO
12	Cristina Carrillo	3	F	NO
13	Olga Arias	2	F	NO
14	Yaned Cardona	4	F	SI
15	Paula Quintero	3	F	NO
16	Jerónimo Martínez	2	M	NO

Id	Colegio_U	Activo_Web	Asistencia	Entregas_Completas	Trabaja	Examen_Final
1	SI	BAJA	0,1	0,45	NO	APROBADO
2	NO	MEDIA	0,45	0,6	NO	APROBADO
3	NO	ALTA	0,5	0,75	SI	DESAPROBADO
4	NO	ALTA	0	0,5	SI	DESAPROBADO
5	NO	MEDIA	0,65	0,85	NO	APROBADO
6	NO	BAJA	0,1	0	NO	DESAPROBADO
7	NO	MEDIA	0,2	0,9	NO	APROBADO
8	NO	MEDIA	0,3	0,8	SI	DESAPROBADO
9	SI	BAJA	0,35	0,7	NO	APROBADO
10	NO	BAJA	0,75	0,5	SI	DESAPROBADO
11	SI	ALTA	0,7	0,6	NO	APROBADO
12	NO	MEDIA	0,9	0,8	NO	APROBADO
13	NO	ALTA	0,2	0,25	NO	DESAPROBADO
14	NO	ALTA	0,2	0,2	NO	DESAPROBADO
15	NO	BAJA	0,9	0,8	NO	APROBADO
16	NO	MEDIA	1	1	NO	APROBADO



Id	Nombre	Estrato	Sexo	Enfermedad	Colegio_U	Activo_Web	Asistencia	Entregas_Completas	Trabaja	Examen_Final
1	Ana Perez	3	F	SI	SI	BAJA	0,1	0,45	NO	APROBADO
2	Mauricio Rios	2	M	NO	NO	MEDIA	0,45	0,6	NO	APROBADO
3	Samuel Ochoa	4	M	NO	NO	ALTA	0,5	0,75	SI	DESAPROBADO
4	Emilia Oviedo	3	F	NO	NO	ALTA	0	0,5	SI	DESAPROBADO
5	Carmen Reyes	4	F	SI	NO	MEDIA	0,65	0,85	NO	APROBADO
6	Alberto Arenas	4	M	NO	NO	BAJA	0,1	0	NO	DESAPROBADO
7	Maria Betancur	3	M	NO	NO	MEDIA	0,2	0,9	NO	APROBADO
8	Manuel Regino	2	M	NO	NO	MEDIA	0,3	0,8	SI	DESAPROBADO
9	Sara Merino	2	F	NO	SI	BAJA	0,35	0,7	NO	APROBADO
10	Pepe Corrales	2	M	SI	NO	BAJA	0,75	0,5	SI	DESAPROBADO
11	Raul Poveda	4	M	NO	SI	ALTA	0,7	0,6	NO	APROBADO
12	Cristina Carrillo	3	F	NO	NO	MEDIA	0,9	0,8	NO	APROBADO
13	Olga Arias	2	F	NO	NO	ALTA	0,2	0,25	NO	DESAPROBADO
14	Yaned Cardona	4	F	SI	NO	ALTA	0,2	0,2	NO	DESAPROBADO
15	Paula Quintero	3	F	NO	NO	BAJA	0,9	0,8	NO	APROBADO
16	Jerónimo Martínez	2	M	NO	NO	MEDIA	1	1	NO	APROBADO



2. Eliminar variables irrelevantes y redundantes

- Eliminar variables irrelevantes para la minería
- Eliminar variables redundantes

Eliminar variables irrelevantes para la minería

Información Irrelevante:

- Nombre
- Teléfono
- Dirección
- Documento de Identificación



2. Eliminar variables irrelevantes y redundantes

- Eliminar variables redundantes matemáticamente

- Edad
- Año de nacimiento

- Nota
- Gana materia

Eliminar redundancias






3. Descripción Estadística de Datos

- **Variables numéricas:** estadística descriptiva y visualización con histogramas de frecuencia, cajas, dispersión.



Edad

Statistic	Value
Minimum	19
Maximum	75
Mean	35.546
StdDev	11.375



3. Descripción Estadística de Datos


- **Variables numéricas:** estadística descriptiva y visualización con histogramas de frecuencia, cajas, dispersión.



4. Limpieza de Datos Atípicos-Errores

- **Datos atípicos (outliers):** valores extremos o inusuales que pueden deberse a variabilidad natural o a errores.


- **Outliers por variabilidad natural:** NO se hace nada
- **Outliers por errores:** asignar NULL



Variable	Regla de calidad
Edad	(18, 90)

Edad	
Statistic	Value
Minimum	19
Maximum	75
Mean	35.546
StdDev	11.375

Variable	Regla de calidad
Sexo	(Mujer, Hombre)



5. Limpieza de Datos Nulos

- Datos faltantes (nulos)

ESTRATEGIA DE LIMPIEZA DE NULOS

1. Eliminar la variables con más del 15% de valores faltantes, excepto si la variable es muy relevante.
2. Imputar variables con máximo 15% de valores faltantes: llenar los campos con la media (numérica simétrica), mediana (numérica asimétrica), moda (categórica), vecino más cercano.

La variable objetivo no se imputa

Id	Nombre	Estrato	Sexo	Enfermedad	Colegio U	Activo Web	Asistencia	Entregas Completas	Trabaja	Examen Final
1	Ana Perez	3	F	SI	SI	BAJA	0,1	0,45	NO	APROBADO
2	Mauricio Rios	2	M	NO	NO	MEDIA	0,45	0,6	NO	APROBADO
3	Samuel Ochoa	4	M	NO	NO	ALTA	0,5	0,75	SI	DESAPROBADO
4	Emilia Oviedo	3	F	NO	NO	ALTA	0	0,5	SI	DESAPROBADO
5	Carmen Reyes	4	F	SI	NO	MEDIA	0,65	0,85	NO	APROBADO
6	Alberto Arenas	4	M	NO	NO	BAJA	0,1	0	NO	DESAPROBADO
7	Maria Betancur	3	M	NO	NO	MEDIA	0,2	0,9	NO	APROBADO
8	Manuel Regino	2	M	NO	NO	MEDIA	0,3	0,8	SI	DESAPROBADO
9	Sara Merino		F	NO	SI	BAJA	0,35	0,7		APROBADO
10	Pepe Corrales	2	M	SI	NO	BAJA	0,75	0,5	SI	DESAPROBADO
11	Raul Poveda	4	M	NO	SI	ALTA	0,7	0,6	NO	APROBADO
12	Cristina Carrillo	3	F	NO	NO	MEDIA	0,9	0,8	NO	APROBADO
13	Olga Arias	2	F	NO	NO	ALTA	0,2	0,25	NO	DESAPROBADO
14	Yaned Cardona	4	F	SI	NO	ALTA	0,2	0,2	NO	DESAPROBADO
15	Paula Quintero	3	F	NO	NO	BAJA	0,9	0,8	NO	APROBADO
16	Jerónimo Martínez	2	M	NO	NO	MEDIA	1	1	NO	APROBADO



6.Transformaciones

Max-Min

$$X_{normalized} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

- Rango de los datos a [0,1]

Selected attribute

Name: preg
Missing: 0 (0%)

Distinct: 17

Type: Numeric
Unique: 2 (0%)

Statistic	Value
Minimum	0
Maximum	1
Mean	0.226
StdDev	0.198



6.Transformaciones

Creación de dummies a las variables predictoras categóricas

Dummies

Ciudad
Medellín
Bogotá
Cali
Cali
Cartagena



Bogotá	Cartagena	Medellín	Cali
0	0	1	0
1	0	0	0
0	0	0	1
0	0	0	1
0	1	0	0

Codificar la variable objetivo cuando es categórica

Codificación

Tipo de cliente

Oro
Plata
Bronce
Oro
Bronce



Oro -> 1
Plata -> 2
Bronce -> 3



Tipo de cliente

1
2
3
1
3






Minería **Descriptiva**



Clustering

Una medida de distancia
determina la similitud entre
los datos.



Los objetos en un grupo deben ser similares o relacionados entre ellos.




Clustering

Id	Atributo 1	Atributo 2	...	Atributo n
1	10	alto		35
2	35	bajo		54
3	43	medio		28
4	26	bajo		65
5	87	alto		32
6	45	alto		29
7	76	bajo		55
8	5	medio		46
9	12	medio		43
10	54	bajo		27

Clustering


Id	Atributo 1	Atributo 2	...	Atributo n	Clúster
1	10	alto		35	
2	35	bajo		54	
3	43	medio		28	
4	26	bajo		65	
5	87	alto		32	
6	45	alto		29	
7	76	bajo		55	
8	5	medio		46	
9	12	medio		43	
10	54	bajo		27	



Clustering




Ciclo de Vida : Clustering



K-means

Divide el conjunto de datos en un número predefinido de grupos.

K-Means es el método más comúnmente utilizado, la idea del método es definir k centroides, uno por clúster, y los datos son asociados al centroide más cercano.





Minería Predictiva





Análisis Predictivo


- Predecir riesgos
- Predecir activación de nuevos clientes
- Series de tiempo
- Predecir inventario

**Predicción
Discreta o
Clasificación**

**Predicción Continua o
Regresión**




Ciclo de Vida : Clasificación y Regresión



División de Datos 70-30



Validación Cruzada (K-fold Cross Validation)



1. Aleatoriamente se divide el conjunto de datos en k subgrupos.
2. Se usan $k-1$ subgrupos en entrenamiento y el otro subgrupo en prueba.
3. Se repite el experimento k veces.

K-Fold Cross Validation


Iteration 01




Iteration 02



Iteration 03



Iteration 04



Iteration 05



dataaspirant.com

Medidas de Evaluación - Regresión

Mediciones de Error:

Métrica	Ecuación
Error cuadrático medio - MSE	$MSE = \sum_{i=1}^n \frac{(Y_i^{real} - Y_i^{pred})^2}{n}$
Raíz del error cuadrático medio - RMSE	$RMSE = \sqrt{MSE}$
Error medio absolute - MAE	$MAE = \frac{1}{n} \sum_{i=1}^n Y_i^{real} - Y_i^{pred} $
Error medio absoluto porcentual - MAPE	$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{ Y_i^{real} - Y_i^{pred} }{ Y_i^{real} }$
Donde n es la cantidad de valores a predecir y Y_i^{pred} y Y_i^{real} representan los valores individuales de la variable objetivo estimada y real, respectivamente. En todas las medidas de error un menor valor implica mejor desempeño.	



Medidas de Evaluación - Clasificación

- Matriz de Confusión →

		Clase Real	
		Clase C_i	NO Clase C_i
Predicción del Clasificador	Positivos para la clase C_i	Verdaderos Positivos (TP)	Falsos Positivos (FP)
	Negativos para la clase C_i	Falsos Negativos (FN)	Verdaderos Negativos (TN)

- Precision → $\frac{TP}{TP + FP}$


- Recall → $\frac{TP}{TP + FN}$

- F1 → $2 \cdot \frac{precision \cdot recall}{precision + recall}$

- Exactitud → $\frac{TP + TN}{TP + TN + FP + FN}$




Arboles de Decisión



Organización jerárquica del espacio de representación, donde cada nodo interior contiene una **pregunta sobre un atributo** concreto y cada nodo hoja se refiere a una decisión (**clase**).



Arboles de Decisión



Arboles de Decisión


Selección de la raíz: se debe evaluar la probabilidad de que cada atributo sea la raíz, buscando mejorar el rendimiento global del árbol.

Índice de información:

Tipo de árbol	Índice de información (criterion)
Árbol de clasificación	Gini
Árbol de regresión	MAE, MSE

Menor valor en el Índice de Gini (impureza):

Probabilidad de etiquetar incorrectamente: impureza de un nodo, o qué tan mezcladas están las clases en él.



Arboles de Decisión

Nivel de profundidad:
profundidad máxima del árbol.


min_samples_leaf:
Número mínimo de muestras que debe haber en cada hoja.

Nivel de profundidad


Profundidad = 1



Profundidad = 2



min_samples_leaf




Random Forest

- Los métodos de ensamble son algoritmos de aprendizaje de máquinas que **construyen un conjunto de predictores** y después clasifican nuevos datos teniendo en cuenta el **voto de sus predicciones**.




- Bagging de datos
- Bagging de características



KNN (K-Nearest Neighbor)

Almacena el conjunto de entrenamiento y al realizar la clasificación se busca en los ejemplos almacenados casos similares y se asigna la clase más probable en éstos. .



```
=== Classifier model (full training set) ===
```



Este curso de formación fue desarrollado en el marco del Proyecto de Investigación "Fortalecimiento de las capacidades nacionales para el aprovechamiento de Fuentes No Convencionales de Energía - **FNCE**, mediante el desarrollo y uso de una plataforma tecnológica multicriterio que favorezca una transición energética justa", con código **1210-951-110321**, financiado por el Ministerio de Ciencia, Tecnología e Innovación (Minciencias) y la Agencia Nacional de Hidrocarburos (ANH) del Gobierno de Colombia a través de la convocatoria "951-2024 Convocatoria Fortalecimiento del Conocimiento Geocientífico y Tecnológico de las Fuentes No Convencionales de Energía y la Captura, Almacenamiento y Uso de CO2" con contrato **No. 049-2025**.



Ciencias



UNIVERSIDAD
DE ANTIOQUIA



UNIVERSIDAD
NACIONAL
DE COLOMBIA



Suélica

Sistema Unificado para la Evaluación de
Límites y Capacidades Energéticas