

Plataforma tecnológica para el Fortalecimiento de las capacidades nacionales  
para el aprovechamiento de Fuentes No Convencionales de Energía

# Analítica de Datos en Python

## IA aplicada a Fuentes No Convencionales de Energía

PhD. Ana Isabel Oviedo | [ana.oviedo@upb.edu.co](mailto:ana.oviedo@upb.edu.co)  
PhD. Ferney Amaya | [Ferney.amaya@upb.edu.co](mailto:Ferney.amaya@upb.edu.co)





# Objetivo del curso

Desarrollar competencias en el análisis de datos con técnicas de Inteligencia Artificial, aplicadas a proyectos de FNCE, mediante el uso Python.



# Desarrollo temático

| Módulo                                                           | Temas principales                                                                                                                    |
|------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------|
| <b>Introducción al análisis de datos con IA</b>                  | Ramas de la IA. Áreas del aprendizaje de máquina. Diseño de soluciones con IA.                                                       |
| <b>Introducción a Python y al análisis exploratorio de datos</b> | Entorno de trabajo de Google Colab, principios de programación, manipulación de datos con Pandas                                     |
| <b>Preparación de datos</b>                                      | Limpieza de nulos y atípicos. Transformaciones: normalización y variables dummy.                                                     |
| <b>Minería descriptiva</b>                                       | Clustering con K-means.                                                                                                              |
| <b>Minería predictiva</b>                                        | División 70-30 y validación cruzada. Medidas de evaluación para clasificación y regresión. Árboles de decision, Random Forest y KNN. |



# Agenda

1. Introducción al Análisis de datos con IA
2. Introducción a Python
3. Preparación de Datos
4. Minería Descriptiva
5. Minería Predictiva



# Introducción al **Análisis de datos con IA**




# IA

Rama de la informática que desarrolla procesos que imitan la inteligencia de los humanos y otros seres vivos.

## Aprendizaje de Máquinas



Predicción de ventas



Detección temprana de enfermedades

## Visión Artificial




Agricultura inteligente




Inspección en manufactura

## Procesamiento de Lenguaje Natural



Asistentes personales




Chatbots

## Robótica



Robot de atención al cliente



Humanoide (Hanson Robotics)

## Agentes Inteligentes




Sistemas autónomos



Automatización de tareas

## IA Generativa



Generación de texto



Generación de audio

# Aprendizaje de máquinas



# Tipos de Datos



## Estructurados

- Variables Numéricas (cuantitativas)
  - Peso
  - Salario
  - Edad
  - Ventas
- Variables Categóricas (cualitativas)
  - Sexo = {Hombre, Mujer}
  - Estado civil= {Casado, Soltero}
  - Estrato= {1,2,3,4,5}

## Fechas (date)

## No Estructurados

- Texto
- Imágenes
- Audio
- Video



# Minería de Datos

Extracción de conocimiento a partir de fuentes masivas de datos.

- Técnicas Estadísticas
- Técnicas de Aprendizaje de Máquinas (IA)



**Transformar datos en conocimiento!**

## Tipos de Análisis en Minería de Datos

### Minería Predictiva



- Predecir riesgos
- Predecir activación de nuevos clientes
- Series de tiempo
- Predecir inventario

### Minería Descriptiva



- Perfil de los clientes
- Selección de factores
- Detección de anomalías
- Canasta de mercado

# Tipos de Análisis en Minería de Datos

## Requerimiento en los Datos:

- Histórico de datos
- Datos etiquetados: existencia de una variable objetivo y varias variables predictoras
- Debe existir relación entre las variables predictoras y la objetivo.

## Minería Predictiva

Predicción Discreta o Clasificación  
Predicción Continua o Regresión






# Minería Predictiva

## Predicción Discreta o Clasificación

Predicción de una variable objetivo categórica.

\* Ejemplo: Predecir los estudiantes que ganarán un curso






# Minería Predictiva

## Predicción Continua o Regresión

Predicción de una variable objetivo numérica.

\* Ejemplo: Estimar la expectativa de vida de un cliente.




# Tipos de Análisis en Minería de Datos

## Requerimiento en los Datos:

- Datos activos o actuales
- Datos No etiquetados

## Minería Descriptiva


### Agrupamiento / Clustering



# Minería Descriptiva


## Agrupamiento / Clustering

Descubrimiento de  
similitudes en los  
datos.




\* Ejemplos: Diseñar  
estrategias de mercadeo  
según el tipo de cliente.  
Detección de anomalías  
identificando datos que se  
alejen de los centroides de  
agrupación

| Id | Atributo 1 | Atributo 2 | ... | Atributo n |
|----|------------|------------|-----|------------|
| 1  | 10         | alto       |     | 35         |
| 2  | 35         | bajo       |     | 54         |
| 3  | 43         | medio      |     | 28         |
| 4  | 26         | bajo       |     | 65         |
| 5  | 87         | alto       |     | 32         |
| 6  | 45         | alto       |     | 29         |
| 7  | 76         | bajo       |     | 55         |
| 8  | 5          | medio      |     | 46         |
| 9  | 12         | medio      |     | 43         |
| 10 | 54         | bajo       |     | 27         |



*Descripción  
en grupos*





# Introducción a **Python**

# Programación

- Código de máquina: 1s y 0s
- Lenguaje ensamblador

```
-u 100 la
```

```
OCFD:0100 BA0B01
OCFD:0103 B409
OCFD:0105 CD21
OCFD:0107 B400
OCFD:0109 CD21
```

```
MOV     DX,010B
MOV     AH,09
INT     21
MOV     AH,00
INT     21
```

Lenguaje de máquina  
del **Intel 8088** (1979).

- Lenguaje de alto nivel

~1842, **Ada Lovrance**

1955 - Fortran

1959 - COBOL

1969 - B (precursor C)

1969 y 1973 - **C**

1980 - **C++** (C con clases)

1983 - Ada

1991 - **Python**

1991 - Visual Basic

1991 - *HTML (Informático)*

1995 - Java

1995 - Delphi (Object Pascal)

1995 - JavaScript

1995 - PHP

2001 - **C#** (Sharp)

2001 - Visual Basic .NET

2005 - Scratch

2009 - Go

2011 - Dart

2014 - Swift



# Enlace de apoyo

<https://github.com/FerneyOAmaya/Competencias-Digitales>



# Proceso de un programa

1. Codificación: se escribe el código fuente del programa: Python, C++ o JavaScript

2. Traducción a Lenguaje de máquina:

- Compilador: Convierte todo el código fuente generando un archivo ejecutable. Lenguaje compilado: C y C++.
- Intérprete: Ejecuta el código línea por línea en tiempo real. Lenguaje interpretado: Python.

3. Ejecución: el sistema operativo (Windows, macOS, Linux y Android) gestiona la ejecución del programa, asignando recursos como memoria y tiempo del procesador.



# Python y Colab



- Gratuito y de código abierto.
- Amplia comunidad de desarrolladores y recursos disponibles.
- Empleado en aprendizaje de máquina (machine learning) y ciencia de datos.



## ¿Qué es Google Colaboratory?

- Colaboratory, o "Colab" para abreviar, es un producto de Google Research.
- Permite escribir y ejecutar código de Python en el navegador.
- Útil para tareas de aprendizaje automático, análisis de datos y educación.







# Google Colab

1 Ingresar a la cuenta de Google.


3 Instalarlo en la cuenta de Google:



2 En Drive:



# Tipos de datos



## ***Case sensitive***

Pasa saber el tipo de dato:

```
type ( )
```

- Snake Case: guiones bajos para separar palabras: `nombre_usuario`.
- Camel Case: La primera letra de cada palabra (excepto la primera) en mayúscula: `nombreUsuario`.
- Mayúsculas  
Constantes: para valores constantes:

```
PI = 3.1416
```



# Restricciones al nombrar variables

- Solo pueden contener letras (a-z, A-Z), números (0-9) y guiones bajos (\_).
- Deben comenzar con letra (a-z, A-Z) o guion bajo (\_).
- No pueden ser palabras reservadas de Python (como if, else, for, while, def).



# Operadores básicos

## Numéricos

| Operación                                                  | En Python |
|------------------------------------------------------------|-----------|
| Adición                                                    | +         |
| Sustracción                                                | -         |
| Multiplicación                                             | *         |
| División                                                   | /         |
| Exponenciación ( $3^2$ en Python sería <code>3**2</code> ) | **        |
| Módulo de la división                                      | %         |
| Resultado de la división redondeando al menor entero       | //        |

## Cadenas de caracteres

| Operación                              | En Python |
|----------------------------------------|-----------|
| Concatenación de cadenas de caracteres | +         |
| Repetición de cadenas de caracteres    | *         |



# Entradas, salidas, casting

Entradas de datos:

```
input()
```

Salidas de datos:

```
print()
```

Observar el tipo de dato:

```
type()
```

*Conversión  
de tipos de  
datos  
(casting):*

a entero:

```
int()
```

a flotante:

```
float()
```

a string:

```
str()
```



# Estructuras de programación

## Condicional

```
if <condición>:  
    ...  
elif:  
    ...  
else:  
    ...  
#END IF
```

## Mientras

```
while <condición>:  
    ...  
#END WHILE
```

## For

```
for <variable compuesta>:  
    ...  
#END FOR
```



# Operadores de comparación

| Comparación          | Símbolo |
|----------------------|---------|
| Igual                | ==      |
| No igual (diferente) | !=      |
| Mayor que            | >       |
| Menor que            | <       |
| Mayor o igual que    | >=      |
| Menor o igual que    | <=      |
| Igual                | ==      |



# Ejemplos de estructuras

```
numero = int(input("Ingresa un número: "))

if numero > 0:
    print("El número es positivo")
elif numero == 0:
    print("El número es cero")
else:
    print("El número es negativo")
```

```
contador = 3

while contador > 0:
    print(contador)
    contador = contador - 1
#END WHILE

print("Despegue")
```

```
cadena = "Hola"

for c in cadena:
    print(c)
```



# Funciones y métodos

**Función:** bloque de código reutilizable.

- Nativa (built-in): `print()`, `len()`, `max()` ...
- Definida por el usuario.

**Método:** asociada a un objeto y tipo de dato:

`objeto.metodo()`

## Funciones

- Facilita la lectura, depuración, distribución de actividades y actualización.
- Pueden reusarse en otros programas.
- Buena práctica: debe ser realizar una única acción, reutilizable y por lo tanto, tan genérica como sea posible.

```
def resta(a, b):  
    c = a - b  
    return c
```

```
valor = resta(6, 2)  
print(valor)
```



# Ejemplos de funciones

```
def imprime():  
    print("Hola mundo!")  
  
imprime()
```

```
def resta(a, b):  
    c = a - b  
    return c  
  
valor = resta(6, 2)  
print(valor)
```

```
def operaciones(a, b):  
    suma = a + b  
    resta = a - b  
    mul = a * b  
    return suma, resta, mul  
  
s, r, m = operaciones(10, 5)  
print("Suma:", s, "Resta:", r, "Mul:", m)
```



# Listas y diccionarios

```
lista = [5, 'hola', [2, 8, 4], ['si', 'no'], "Python"]
```

```
traductor = {  
    "apple": "manzana",  
    "banana": "plátano",  
    "orange": "naranja",  
    "strawberry": "fresa",  
    "grape": "uva"  
}
```



# Pandas

Un DataFrame es una tabla bidimensional para manejar datos (filas y columnas).

**Ejemplo:**

| Índice | Nombre | Edad | Ciudad   |
|--------|--------|------|----------|
| 0      | Ana    | 22   | Bogotá   |
| 1      | Luis   | 28   | Medellín |
| 2      | Marta  | 24   | Cali     |

Valores

- Fila, Columna
- Nombre de la columna
- Índices
- Valores



# Pandas - Crear

## Creación:

| Índice | A | B |
|--------|---|---|
| 10     | 1 | 2 |
| 20     | 3 | 4 |
| 30     | 5 | 6 |

```
import numpy as np
import pandas as pd

datos = np.array([[1, 2], [3, 4], [5, 6]])
df = pd.DataFrame(datos, index=[10, 20, 30], columns=['A', 'B'])

df = pd.DataFrame(
    {'A': [1, 2, 3], 'B': [4, 5, 6]}, index=[10, 20, 30])
```

## Exploración:

- df.columns
- df.index
- df.values
- df.dtypes
- df.loc[índice , nombre\_columna]
- df.iloc[posicion\_fila, posicion\_columna]



# Pandas – Crear y cargar

Importar desde un archivo

Formatos  
almacenamiento

| Id | Nombre | Edad | Hijos |
|----|--------|------|-------|
| 0  | Jorge  | 28   | 2     |
| 1  | Carlos | 36   |       |
| 2  | Lina   |      | 1     |
| 3  | Sofía  | 40   | 0     |

## JSON: (JavaScript Object Notation)

```
{  
  "Nombre":  
    :{"0":"Jorge", "1":"Carlos", "2":"Lina", "3":"Sofía"},  
  "Edad":  
    :{"0":28,"1":36,"2":null,"3":40},  
  "Hijos":  
    :{"0":2,"1":null,"2":1,"3":0} }  
}
```

## CSV: (comma-separated values)

```
Id,Nombre,Edad,Hijos  
0,Jorge,28,2  
1,Carlos,36,  
2,Lina,,1  
3,Sofía,40,0
```



# Pandas – Consultar

## Acciones:

- Valores únicos: `.unique()`
- Acceder: `.loc[]`, `.iloc[]`
- Calcular: `.max()`, `.min()`
- No nulos: `.notnull()`
- Filtrar: `.between()`
- Ordenar: `sort_values()`

Desde: Github Ferney Amaya → Competencias-Digitales → Libro “Librería Pandas” → Cargar el Dataframe de la sección 5

<https://github.com/FerneyOAmaya/Competencias-Digitales>



# Pandas - groupby

```
df.groupby([col1, col2 ...])[col_val1, col_val2 ...].función_agregación()
```

- col1, col2 ... : columnas a agrupar
- col\_val: columnas a aplicar la función de agregación
- función\_agregación: Ejemplos: `sum()`, `mean()`, `count()`

Desde: Github Ferney Amaya → Competencias-Digitales → Libro “Librería Pandas” → Cargar el Dataframe de la sección 5

<https://github.com/FerneyOAmaya/Competencias-Digitales>





# Preparación de Datos



# Preparación de los Datos

1. Integración de los datos
2. Eliminar variables irrelevantes y redundantes
3. Descripción estadística de los datos
4. Limpieza de datos atípicos-errores
5. Limpieza de datos nulos
6. Transformaciones según el método de ML
  - Normalización
  - Creación de dummies



# 1. Integración de Datos

Se debe crear un registro por persona/producto/servicio/sede con todas las variables integradas:

**ELIMINAR**  
registros con lds  
duplicados

| Id | Nombre            | Estrato | Sexo | Enfermedad |
|----|-------------------|---------|------|------------|
| 1  | Ana Perez         | 3       | F    | SI         |
| 2  | Mauricio Rios     | 2       | M    | NO         |
| 3  | Samuel Ochoa      | 4       | M    | NO         |
| 4  | Emilia Oviedo     | 3       | F    | NO         |
| 5  | Carmen Reyes      | 4       | F    | SI         |
| 6  | Alberto Arenas    | 4       | M    | NO         |
| 7  | Maria Betancur    | 3       | M    | NO         |
| 8  | Manuel Regino     | 2       | M    | NO         |
| 9  | Sara Merino       | 2       | F    | NO         |
| 10 | Pepe Corrales     | 2       | M    | SI         |
| 11 | Raul Poveda       | 4       | M    | NO         |
| 12 | Cristina Carrillo | 3       | F    | NO         |
| 13 | Olga Arias        | 2       | F    | NO         |
| 14 | Yaned Cardona     | 4       | F    | SI         |
| 15 | Paula Quintero    | 3       | F    | NO         |
| 16 | Jerónimo Martínez | 2       | M    | NO         |

| Id | Colegio_U | Activo_Web | Asistencia | Entregas_Completas | Trabaja | Examen_Final |
|----|-----------|------------|------------|--------------------|---------|--------------|
| 1  | SI        | BAJA       | 0,1        | 0,45               | NO      | APROBADO     |
| 2  | NO        | MEDIA      | 0,45       | 0,6                | NO      | APROBADO     |
| 3  | NO        | ALTA       | 0,5        | 0,75               | SI      | DESAPROBADO  |
| 4  | NO        | ALTA       | 0          | 0,5                | SI      | DESAPROBADO  |
| 5  | NO        | MEDIA      | 0,65       | 0,85               | NO      | APROBADO     |
| 6  | NO        | BAJA       | 0,1        | 0                  | NO      | DESAPROBADO  |
| 7  | NO        | MEDIA      | 0,2        | 0,9                | NO      | APROBADO     |
| 8  | NO        | MEDIA      | 0,3        | 0,8                | SI      | DESAPROBADO  |
| 9  | SI        | BAJA       | 0,35       | 0,7                | NO      | APROBADO     |
| 10 | NO        | BAJA       | 0,75       | 0,5                | SI      | DESAPROBADO  |
| 11 | SI        | ALTA       | 0,7        | 0,6                | NO      | APROBADO     |
| 12 | NO        | MEDIA      | 0,9        | 0,8                | NO      | APROBADO     |
| 13 | NO        | ALTA       | 0,2        | 0,25               | NO      | DESAPROBADO  |
| 14 | NO        | ALTA       | 0,2        | 0,2                | NO      | DESAPROBADO  |
| 15 | NO        | BAJA       | 0,9        | 0,8                | NO      | APROBADO     |
| 16 | NO        | MEDIA      | 1          | 1                  | NO      | APROBADO     |



| Id | Nombre            | Estrato | Sexo | Enfermedad | Colegio_U | Activo_Web | Asistencia | Entregas_Completas | Trabaja | Examen_Final |
|----|-------------------|---------|------|------------|-----------|------------|------------|--------------------|---------|--------------|
| 1  | Ana Perez         | 3       | F    | SI         | SI        | BAJA       | 0,1        | 0,45               | NO      | APROBADO     |
| 2  | Mauricio Rios     | 2       | M    | NO         | NO        | MEDIA      | 0,45       | 0,6                | NO      | APROBADO     |
| 3  | Samuel Ochoa      | 4       | M    | NO         | NO        | ALTA       | 0,5        | 0,75               | SI      | DESAPROBADO  |
| 4  | Emilia Oviedo     | 3       | F    | NO         | NO        | ALTA       | 0          | 0,5                | SI      | DESAPROBADO  |
| 5  | Carmen Reyes      | 4       | F    | SI         | NO        | MEDIA      | 0,65       | 0,85               | NO      | APROBADO     |
| 6  | Alberto Arenas    | 4       | M    | NO         | NO        | BAJA       | 0,1        | 0                  | NO      | DESAPROBADO  |
| 7  | Maria Betancur    | 3       | M    | NO         | NO        | MEDIA      | 0,2        | 0,9                | NO      | APROBADO     |
| 8  | Manuel Regino     | 2       | M    | NO         | NO        | MEDIA      | 0,3        | 0,8                | SI      | DESAPROBADO  |
| 9  | Sara Merino       | 2       | F    | NO         | SI        | BAJA       | 0,35       | 0,7                | NO      | APROBADO     |
| 10 | Pepe Corrales     | 2       | M    | SI         | NO        | BAJA       | 0,75       | 0,5                | SI      | DESAPROBADO  |
| 11 | Raul Poveda       | 4       | M    | NO         | SI        | ALTA       | 0,7        | 0,6                | NO      | APROBADO     |
| 12 | Cristina Carrillo | 3       | F    | NO         | NO        | MEDIA      | 0,9        | 0,8                | NO      | APROBADO     |
| 13 | Olga Arias        | 2       | F    | NO         | NO        | ALTA       | 0,2        | 0,25               | NO      | DESAPROBADO  |
| 14 | Yaned Cardona     | 4       | F    | SI         | NO        | ALTA       | 0,2        | 0,2                | NO      | DESAPROBADO  |
| 15 | Paula Quintero    | 3       | F    | NO         | NO        | BAJA       | 0,9        | 0,8                | NO      | APROBADO     |
| 16 | Jerónimo Martínez | 2       | M    | NO         | NO        | MEDIA      | 1          | 1                  | NO      | APROBADO     |



## 2. Eliminar variables irrelevantes y redundantes

- Eliminar variables irrelevantes para la minería
- Eliminar variables redundantes

Eliminar variables irrelevantes para la minería

### Información Irrelevante:

- Nombre
- Teléfono
- Dirección
- Documento de Identificación



## 2. Eliminar variables irrelevantes y redundantes

- Eliminar variables redundantes matemáticamente

- Edad
- Año de nacimiento

- Nota
- Gana materia

Eliminar redundancias






# 3. Descripción Estadística de Datos

- **Variables numéricas:** estadística descriptiva y visualización con histogramas de frecuencia, cajas, dispersión.



Edad

| Statistic | Value  |
|-----------|--------|
| Minimum   | 19     |
| Maximum   | 75     |
| Mean      | 35.546 |
| StdDev    | 11.375 |



### 3. Descripción Estadística de Datos


- **Variables categóricas:** estadística descriptiva y visualización con barras y tortas



## 4. Limpieza de Datos Atípicos-Errores

- **Datos atípicos (outliers):** valores extremos o inusuales que pueden deberse a variabilidad natural o a errores.


- **Outliers por variabilidad natural:** NO se hace nada
- **Outliers por errores:** asignar NULL



| Variable | Regla de calidad |
|----------|------------------|
| Edad     | (18, 90)         |

| Edad      |        |
|-----------|--------|
| Statistic | Value  |
| Minimum   | 19     |
| Maximum   | 75     |
| Mean      | 35.546 |
| StdDev    | 11.375 |

| Variable | Regla de calidad |
|----------|------------------|
| Sexo     | (Mujer, Hombre)  |



# 5. Limpieza de Datos Nulos

## ESTRATEGIA DE LIMPIEZA DE NULOS

1. Eliminar la variables con más del 15% de valores faltantes, excepto si la variable es muy relevante.
2. Imputar variables con máximo 15% de valores faltantes: llenar los campos con la media (numérica simétrica), mediana (numérica asimétrica), moda (categórica), vecino más cercano.

La variable objetivo no se imputa

| Id | Nombre            | Estrato | Sexo | Enfermedad | Colegio U | Activo Web | Asistencia | Entregas Completas | Trabaja | Examen Final |
|----|-------------------|---------|------|------------|-----------|------------|------------|--------------------|---------|--------------|
| 1  | Ana Perez         | 3       | F    | SI         | SI        | BAJA       | 0,1        | 0,45               | NO      | APROBADO     |
| 2  | Mauricio Rios     | 2       | M    | NO         | NO        | MEDIA      | 0,45       | 0,6                | NO      | APROBADO     |
| 3  | Samuel Ochoa      | 4       | M    | NO         | NO        | ALTA       | 0,5        | 0,75               | SI      | DESAPROBADO  |
| 4  | Emilia Oviedo     | 3       | F    | NO         | NO        | ALTA       | 0          | 0,5                | SI      | DESAPROBADO  |
| 5  | Carmen Reyes      | 4       | F    | SI         | NO        | MEDIA      | 0,65       | 0,85               | NO      | APROBADO     |
| 6  | Alberto Arenas    | 4       | M    | NO         | NO        | BAJA       | 0,1        | 0                  | NO      | DESAPROBADO  |
| 7  | Maria Betancur    | 3       | M    | NO         | NO        | MEDIA      | 0,2        | 0,9                | NO      | APROBADO     |
| 8  | Manuel Regino     | 2       | M    | NO         | NO        | MEDIA      | 0,3        | 0,8                | SI      | DESAPROBADO  |
| 9  | Sara Merino       |         | F    | NO         | SI        | BAJA       | 0,35       | 0,7                |         | APROBADO     |
| 10 | Pepe Corrales     | 2       | M    | SI         | NO        | BAJA       | 0,75       | 0,5                | SI      | DESAPROBADO  |
| 11 | Raul Poveda       | 4       | M    | NO         | SI        | ALTA       | 0,7        | 0,6                | NO      | APROBADO     |
| 12 | Cristina Carrillo | 3       | F    | NO         | NO        | MEDIA      | 0,9        | 0,8                | NO      | APROBADO     |
| 13 | Olga Arias        | 2       | F    | NO         | NO        | ALTA       | 0,2        | 0,25               | NO      | DESAPROBADO  |
| 14 | Yaned Cardona     | 4       | F    | SI         | NO        | ALTA       | 0,2        | 0,2                | NO      | DESAPROBADO  |
| 15 | Paula Quintero    | 3       | F    | NO         | NO        | BAJA       | 0,9        | 0,8                | NO      | APROBADO     |
| 16 | Jeronimo Martinez | 2       | M    | NO         | NO        | MEDIA      | 1          | 1                  | NO      | APROBADO     |



## 6.Transformaciones - Normalización

Max-Min

$$X_{normalized} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

- Rango de los datos a [0,1]

| Selected attribute |              |                |
|--------------------|--------------|----------------|
| Name: preg         | Distinct: 17 | Type: Numeric  |
| Missing: 0 (0%)    |              | Unique: 2 (0%) |
| Statistic          | Value        |                |
| Minimum            | 0            |                |
| Maximum            | 1            |                |
| Mean               | 0.226        |                |
| StdDev             | 0.198        |                |



# 6.Transformaciones - Dummies

Creación de dummies a las variables predictoras categóricas

Ciudad  
Medellín  
Bogotá  
Cali  
Cali  
Cartagena



Dummies

| Bogotá | Cartagena | Medellín | Cali |
|--------|-----------|----------|------|
| 0      | 0         | 1        | 0    |
| 1      | 0         | 0        | 0    |
| 0      | 0         | 0        | 1    |
| 0      | 0         | 0        | 1    |
| 0      | 1         | 0        | 0    |

- Si son 2 dummies se borra una de ellas
- Si son 3 o más dummies no se borra ninguna






# Minería **Descriptiva**



# Clustering

Una medida de distancia  
determina la similitud entre  
los datos.



Los objetos en un grupo deben ser similares o relacionados entre ellos.




# Clustering

| Id | Atributo 1 | Atributo 2 | ... | Atributo n |
|----|------------|------------|-----|------------|
| 1  | 10         | alto       |     | 35         |
| 2  | 35         | bajo       |     | 54         |
| 3  | 43         | medio      |     | 28         |
| 4  | 26         | bajo       |     | 65         |
| 5  | 87         | alto       |     | 32         |
| 6  | 45         | alto       |     | 29         |
| 7  | 76         | bajo       |     | 55         |
| 8  | 5          | medio      |     | 46         |
| 9  | 12         | medio      |     | 43         |
| 10 | 54         | bajo       |     | 27         |

Clustering


| Id | Atributo 1 | Atributo 2 | ... | Atributo n | Clúster |
|----|------------|------------|-----|------------|---------|
| 1  | 10         | alto       |     | 35         |         |
| 2  | 35         | bajo       |     | 54         |         |
| 3  | 43         | medio      |     | 28         |         |
| 4  | 26         | bajo       |     | 65         |         |
| 5  | 87         | alto       |     | 32         |         |
| 6  | 45         | alto       |     | 29         |         |
| 7  | 76         | bajo       |     | 55         |         |
| 8  | 5          | medio      |     | 46         |         |
| 9  | 12         | medio      |     | 43         |         |
| 10 | 54         | bajo       |     | 27         |         |



Clustering




# Ciclo de Vida : Clustering



# K-means

Divide el conjunto de datos en un número predefinido de grupos.

K-Means es el método más comúnmente utilizado, la idea del método es definir  $k$  centroides, uno por clúster, y los datos son asociados al centroide más cercano.





# Minería Predictiva





# Análisis Predictivo


- Predecir riesgos
- Predecir activación de nuevos clientes
- Series de tiempo
- Predecir inventario

**Predicción  
Discreta o  
Clasificación**


**Predicción Continua o  
Regresión**




# Ciclo de Vida : Clasificación y Regresión



# División de Datos 70-30



# Validación Cruzada (K-fold Cross Validation)




1. Aleatoriamente se divide el conjunto de datos en  $k$  subgrupos.
2. Se usan  $k-1$  subgrupos en entrenamiento y el otro subgrupo en prueba.
3. Se repite el experimento  $k$  veces.

## K-Fold Cross Validation


Iteration 01




Iteration 02



Iteration 03



Iteration 04



Iteration 05



[dataaspirant.com](http://dataaspirant.com)

# Medidas de Evaluación - Regresión

Mediciones de Error:

| Métrica                                                                                                                                                                                                                                                                                   | Ecuación                                                                         |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------|
| Error cuadrático medio - MSE                                                                                                                                                                                                                                                              | $MSE = \sum_{i=1}^n \frac{(Y_i^{real} - Y_i^{pred})^2}{n}$                       |
| Raíz del error cuadrático medio - RMSE                                                                                                                                                                                                                                                    | $RMSE = \sqrt{MSE}$                                                              |
| Error medio absolute - MAE                                                                                                                                                                                                                                                                | $MAE = \frac{1}{n} \sum_{i=1}^n  Y_i^{real} - Y_i^{pred} $                       |
| Error medio absoluto porcentual - MAPE                                                                                                                                                                                                                                                    | $MAPE = \frac{1}{n} \sum_{i=1}^n \frac{ Y_i^{real} - Y_i^{pred} }{ Y_i^{real} }$ |
| <p>Donde <math>n</math> es la cantidad de valores a predecir y <math>Y_i^{pred}</math> y <math>Y_i^{real}</math> representan los valores individuales de la variable objetivo estimada y real, respectivamente. En todas las medidas de error un menor valor implica mejor desempeño.</p> |                                                                                  |



# Medidas de Evaluación - Clasificación

- Matriz de Confusión →

|                             |                               | Clase Real                |                           |
|-----------------------------|-------------------------------|---------------------------|---------------------------|
|                             |                               | Clase $C_i$               | NO Clase $C_i$            |
| Predicción del Clasificador | Positivos para la clase $C_i$ | Verdaderos Positivos (TP) | Falsos Positivos (FP)     |
|                             | Negativos para la clase $C_i$ | Falsos Negativos (FN)     | Verdaderos Negativos (TN) |

- Precision →  $\frac{TP}{TP + FP}$


- Recall →  $\frac{TP}{TP + FN}$

- F1 →  $2 \cdot \frac{precision \cdot recall}{precision + recall}$

- Exactitud →  $\frac{TP + TN}{TP + TN + FP + FN}$




# Arboles de Decisión



Organización jerárquica del espacio de representación, donde cada nodo interior contiene una **pregunta sobre un atributo** concreto y cada nodo hoja se refiere a una decisión (**clase**).



# Arboles de Decisión



# Arboles de Decisión


**Selección de la raíz:** se debe evaluar la probabilidad de que cada atributo sea la raíz, buscando mejorar el rendimiento global del árbol.

## Índice de información:

| Tipo de árbol          | Índice de información (criterion) |
|------------------------|-----------------------------------|
| Árbol de clasificación | Gini                              |
| Árbol de regresión     | MAE, MSE                          |

## Menor valor en el Índice de Gini (impureza):

Probabilidad de etiquetar incorrectamente:  
impureza de un nodo, o qué tan mezcladas  
están las clases en él.



# Arboles de Decisión


**Nivel de profundidad:**  
profundidad máxima del árbol.

## Nivel de profundidad

**Profundidad = 1**




**Profundidad = 2**



**min\_samples\_leaf:**  
Número mínimo de muestras que debe haber en cada hoja.

## min\_samples\_leaf




# Random Forest

- Los métodos de ensamble son algoritmos de aprendizaje de máquinas que **construyen un conjunto de predictores** y después clasifican nuevos datos teniendo en cuenta el **voto de sus predicciones**.




- Bagging de datos
- Bagging de características



# KNN (K-Nearest Neighbor)

Almacena el conjunto de entrenamiento y al realizar la clasificación se busca en los ejemplos almacenados casos similares y se asigna la clase más probable en éstos. .



```
=== Classifier model (full training set) ===
```



---

Este curso de formación fue desarrollado en el marco del Proyecto de Investigación "Fortalecimiento de las capacidades nacionales para el aprovechamiento de Fuentes No Convencionales de Energía - **FNCE**, mediante el desarrollo y uso de una plataforma tecnológica multicriterio que favorezca una transición energética justa", con código **1210-951-110321**, financiado por el Ministerio de Ciencia, Tecnología e Innovación (Minciencias) y la Agencia Nacional de Hidrocarburos (ANH) del Gobierno de Colombia a través de la convocatoria "951-2024 Convocatoria Fortalecimiento del Conocimiento Geocientífico y Tecnológico de las Fuentes No Convencionales de Energía y la Captura, Almacenamiento y Uso de CO2" con contrato **No. 049-2025**.



Ciencias



UNIVERSIDAD  
DE ANTIOQUIA



UNIVERSIDAD  
NACIONAL  
DE COLOMBIA



# Suélica

Sistema Unificado para la Evaluación de  
Límites y Capacidades Energéticas